




Das ist eine sehr gute Frage. Tatsächlich bewegen sich viele aktuelle Entwicklungen bei KI-Agenten weg vom reinen "größeren LLM" hin zu **besserem Gedächtnis, effizienterem Wissen und lokaler Ausführung**. Das passt auch gut zu deinem Interesse an **SLMs (Small Language Models)** und **WebAssembly/WebGPU**.

Die Bausteine eines modernen Cognitive Agents

Man kann sich einen Agenten wie einen Menschen vorstellen:

Wahrnehmung

↓

Kurzzeitgedächtnis

↓

Denken / Planen

↓

Langzeitgedächtnis

↓

Werkzeuge benutzen

↓

Lernen

Die eigentliche Innovation steckt heute oft **nicht mehr im LLM**, sondern in den anderen Bausteinen.

1. Working Memory (Kurzzeitgedächtnis)

- Aktuelle Unterhaltung
- Aktuelle Aufgabe
- Temporäre Notizen

Beispiel:

"Ich entwickle gerade einen Docker-Container."

Dieses Wissen wird nur während der Aufgabe benötigt.

2. Episodic Memory

Wie beim Menschen:

"Vor drei Wochen hast du ein Kubernetes-Projekt begonnen."

Der Agent erinnert sich an frühere Ereignisse.

3. Semantic Memory

Das ist **Faktenwissen**.

Beispiel:

- Docker Compose

- Kubernetes
- LangGraph
- Azure

Dieses Wissen stammt häufig aus Dokumenten, Wikis oder Handbüchern.

4. Procedural Memory

Nicht nur **was** man weiß, sondern **wie** man etwas macht.

Beispiel:

"So wird ein Kubernetes-Cluster eingerichtet."

Das sind Arbeitsabläufe und Skills.

5. RAG (Retrieval-Augmented Generation)

RAG bedeutet:

- Dokumente speichern.
- Bei einer Frage die relevanten Informationen suchen.
- Diese Informationen dem LLM als Kontext geben.

Heute nutzen viele Systeme dafür Vektordatenbanken.

6. Knowledge Graphs

Statt nur Dokumente zu speichern, werden Beziehungen modelliert.

Zum Beispiel:

Docker

↓

Container

Container

↓

Kubernetes

Kubernetes

↓

Helm

Das hilft bei komplexen Schlussfolgerungen.

7. Tool Memory

Der Agent merkt sich:

- Welche Tools vorhanden sind.
 - Wann welches Tool erfolgreich war.
 - Welche Reihenfolge gut funktioniert.
-

8. Skill Memory

Hier entsteht ein wiederverwendbarer Skill.

Beispiel:

Docker installieren

↓

Script erzeugen

↓

Dokumentation erstellen

=> neuer Skill

Genau hier setzen einige Cognitive-Agent-Systeme an.

Neue Trends (2025–2026)

Die Forschung bewegt sich unter anderem in diese Richtungen:

- **Hierarchische Memory-Systeme** (mehrere Gedächtnisebenen)
- **GraphRAG** (RAG + Wissensgraphen)
- **Agentic Memory** (Agenten entscheiden selbst, was gespeichert wird)
- **Reflective Memory** (Agent bewertet seine eigene Arbeit und lernt daraus)

- **Long-term Memory** (dauerhaftes Gedächtnis über Wochen oder Monate)
 - **Hybrid Memory** (Vektoren + Graphen + strukturierte Daten)
-

Wo sehe ich deine Nische?

Aus unseren Gesprächen kenne ich deine Interessen:

- lokale KI
- Datenschutz
- Raspberry Pi
- Docker
- LangGraph
- KMU
- Edge AI

Ich würde **nicht** versuchen, das nächste große LLM zu bauen.

Stattdessen sehe ich Potenzial in einer Kombination aus:

SLM

+

Memory

+

Edge AI

+

WebGPU

+

WebAssembly

Das ist ein Bereich, in dem viele Unternehmen noch nach praxistauglichen Lösungen suchen.

Eine mögliche Spezialisierung

Edge Cognitive AI Platform

Bausteine:

- Kleine Modelle (SLMs)

- Lokales Memory
- RAG
- Langzeitgedächtnis
- Browser-Ausführung über WebAssembly/WebGPU
- Datenschutz
- Offline-Betrieb

Das wäre für KMU interessant, die keine sensiblen Daten in die Cloud schicken möchten.

Eine Roadmap für dich

1. **SLMs** verstehen und einsetzen (z. B. Gemma, Phi, Qwen in kleinen Varianten).
2. **Memory-Systeme** (Working, Episodic, Semantic, Procedural) praktisch implementieren.
3. **RAG** und später **GraphRAG** aufbauen.
4. **WebAssembly** lernen, damit KI im Browser laufen kann.
5. **WebGPU** nutzen, um lokale Inferenz im Browser zu beschleunigen.
6. Diese Bausteine in dein **TRACE AI OS** integrieren.

Warum ich das für eine starke Nische halte

Viele Entwickler können heute ein LLM per API aufrufen. Deutlich seltener sind Fachleute, die **lokale, datenschutzfreundliche Cognitive-Agenten mit effizientem Gedächtnis** entwickeln und sie auf Edge-Geräten oder im Browser performant betreiben können.

Mit deinem Hintergrund in IT-Systemadministration, Docker und Plattformen könntest du dich genau an dieser Schnittstelle positionieren: **Edge AI + Agenten + Memory + Web-Technologien**. Das ist ein klareres Profil als einfach nur "KI-Entwickler" und passt gut zu deiner langfristigen Vision für TRACE AI.

Deine lokale KI-Fabrik → Browser-KI-Produkte

Ein Fundament auf deinem Rechner · viele Produkte · Nische: SLM + WebAssembly/WebGPU + OSINT

EBENE 1 · STEUERUNG (DU)

VS Code + Claude Code
Entwicklung & Agent-Delegation

Projekt-Backlog (Git)
Ideen → Issues → Releases

Content-Plan
YouTube „KI ohne Cloud“ · LinkedIn

Wissensbasis / Notizen
Recherche, Prompts, Learnings

EBENE 2 · FABRIK-DIENSTE (DOCKER, LOKAL AUF DEINEM RECHNER)

Ollama / LiteLLM
SLM-Labor: Qwen, Gemma, Phi

n8n
Automatisierung & Pipelines

Qdrant
Vektor-DB für RAG-Tests

SearXNG
OSINT-/Markt-Recherche

MinIO / Postgres
Artefakte & Daten

Rolle der Fabrik: Modelle vergleichen (Deutsch-Qualität), Prompts entwickeln, Inhalte recherchieren, MLC-Modelle für WebLLM vorbereiten — die Fabrik ist die Werkstatt, nicht das Produkt.

EBENE 3 · PRODUKTIONS-PIPELINE (PRO PRODUKT)

1 · Bauen
HTML/JS + WebLLM + pdf.js

2 · Testen
Chrome/Edge · WebGPU · Geräte

3 · Veröffentlichen
Cloudflare Pages (statisch, 0 €)

4 · Vermarkten
Video + Post + Newsletter

EBENE 4 · PRODUKTE (AUS EINEM FUNDAMENT)

DokuCheck Lokal
JETZT · Lead-Magnet
+ Portfolio-Beweis
für die Nische

Weitere Browser-Tools
DE→VI-Erklärer
Bewerbungs-Checker
OSINT-Report-Analyzer

Bezahlprodukte
Kurs „Browser-KI bauen“
Template-Bibliothek
Beratung / Auftragsarbeit

KUNDENSEITE · BROWSER DES NUTZERS

WebLLM + WebGPU (Fallback: WASM)
SLM läuft auf dem Gerät des Kunden
Dokumente verlassen das Gerät nie
0 € Hosting · DSGVO by Design

Prinzip „Fabrik, nicht Produkt“: Ebenen 1–3 bleiben für jedes künftige Produkt gleich — nur Ebene 4 wächst. Jedes neue Tool kostet dadurch nur noch Tage statt Wochen.

Stand: Juli 2026 · Nische: SLM · WebAssembly/WebGPU · Browser-Agenten · OSINT-Automatisierung