

Titel und Einleitung

Architektur- und Technikplan für DokuCheck Lokal

Dieses Dokument beschreibt eine empfohlene Architektur und Konfiguration für das Produkt „DokuCheck Lokal“ von vuxuantiep.de. Der Fokus liegt auf einer lokalen, browserbasierten KI-Dokumentenanalyse mit WebLLM, WebGPU, OCR und PDF-Verarbeitung.[[github](#)]

1. Zielsetzung und Überblick

Ziel von DokuCheck Lokal ist es, Verträge, Behördenbriefe und andere sensible Dokumente vollständig lokal im Webbrowser zu analysieren, zusammenzufassen und zu übersetzen, ohne dass Daten den Rechner verlassen.[[golem](#)]

Die Anwendung soll **leicht** nutzbar sein, Datenschutz garantieren und typische Prüfaufgaben wie Fristen-, Kosten- und Kündigungs-Checks unterstützen.[[localhost](#)]

2. Architekturübersicht

Die Architektur von DokuCheck Lokal folgt einem rein clientseitigen Ansatz:[[web](#)]

- Frontend-Webapp (HTML/CSS/JavaScript, Framework nach Wahl, z. B. React/Vue/Svelte).
- WebLLM als Inferenz-Engine für kleine LLM-Modelle im Browser (z. B. Llama-3.2 und Qwen2/Qwen2.5).[[github](#)]
- WebGPU als Hardware-Beschleuniger für die Modellinferenz, wenn verfügbar.[[github](#)]
- OCR-Schicht mit Tesseract.js für Bilder und gescannte Dokumente.[[cradl](#)]
- PDF-Verarbeitung mit pdf.js zur Extraktion von Text und Layout-Informationen aus PDFs.[[cradl](#)]
- IndexedDB als lokaler Speicher für Modelle, Dokumente, Analyse-Historie und Skills.[[localhost](#)]

3. Modell-Setup mit WebLLM

Für eine gute Balance aus Qualität und Performance im Browser werden folgende Modell-Presets empfohlen:[[github](#)]

- Preset „Schnell & leicht“: Qwen2 0.5B oder Llama-3.2-1B – geeignet für schwächere GPUs, Notebooks und mobile Geräte.[[gist.github](#)]
- Preset „Präzise & gründlich“: Llama-3.2-3B oder Phi-3.5-3B – für Desktop-Systeme mit stärkerer GPU (WebGPU aktiviert).[[localaimaster](#)]

Konfigurationsempfehlungen für WebLLM:[[github](#)]

- Temperature niedrig halten (z. B. 0,2–0,4) für juristische Texte, um Halluzinationen zu reduzieren.
- Maximale Antwortlänge begrenzen (z. B. 512–1024 Tokens), um Fokus zu erzwingen.
- Repetition-Penalty moderat setzen, damit Zusammenfassungen nicht redundant werden.

4. Verbesserte OCR- und PDF-Pipeline

Die Qualität der Analyse hängt direkt von der Qualität der Textextraktion ab. Es werden folgende Verbesserungen vorgeschlagen:[[cradl](#)]

- Bildvorverarbeitung (Rotation, Kontrastanhebung, Binarisierung), bevor Tesseract.js ausgeführt wird.
- Layout-Erhaltung: Segmentierung von Seiten in Blöcke (Absätze, Tabellen, Überschriften) statt flachem Volltext.
- Sprachprofile gezielt setzen (Deutsch, Englisch, Vietnamesisch) pro Seite oder Dokument, basierend auf einer vorgeschalteten Spracherkennung.
- Separate Extraktion von Metadaten (Titel, Dokumenttyp, Datum, Parteien) für gezielte Prompts.

5. Prompt-Design und Skills für Dokumenten-Checks

DokuCheck Lokal arbeitet mit wiederverwendbaren Skills (z. B. Fristen-Check, Kosten-Check, Kündigungs-Check). Für hohe Qualität sollte das Prompt-Design klar strukturiert sein.[[localhost](#)]

Beispiel-Systemprompt (Deutsch, Vertragsprüfung):

Du bist ein Vertragsprüfer für deutsche Verbraucherverträge. Du ersetzt keine Rechtsberatung, sollst aber Risiken, Kosten, Fristen und Kündigungsbedingungen strukturiert markieren. Analysiere den folgenden Vertragstext und gib die Antwort in vier Sektionen:

1. Zusammenfassung (maximal 10 Sätze)
2. Fristen (Liste mit Datum und Ereignis)
3. Kosten & Gebühren (Liste mit Betrag und Bedingung)
4. Kündigung & Verlängerung (Beschreibung der Mindestlaufzeit, Kündigungsfrist und automatischer Verlängerung).

Wenn Textstellen unklar sind oder durch OCR Fehler enthalten, markiere sie mit „UNKLAR“ und erfinde nichts hinzu.

Ví dụ Prompt hệ thống (Tiếng Việt, kiểm tra hợp đồng):

Bạn là một trợ lý kiểm tra hợp đồng dành cho người tiêu dùng tại Đức. Bạn không thay thế luật sư, nhưng cần chỉ ra rủi ro, chi phí, thời hạn và điều kiện chấm dứt hợp đồng một cách rõ ràng. Phân tích văn bản hợp đồng sau và trả lời theo 4 phần:

1. Tóm tắt (tối đa 10 câu)
2. Thời hạn & mốc thời gian (danh sách ngày và sự kiện)
3. Chi phí & phí (danh sách số tiền và điều kiện áp dụng)
4. Chấm dứt & gia hạn (mô tả thời hạn tối thiểu, thời gian báo hủy và việc gia hạn tự động).

Nếu có đoạn văn không rõ hoặc sai do OCR, hãy ghi „KHÔNG RÕ“ và không được tự bịa thêm.

6. RAG-Light und Kontextsteuerung im Browser

Um lange Dokumente effizient zu verarbeiten, kann DokuCheck Lokal ein leichtes RAG-Konzept im Browser nutzen.[\[github\]](#)

- Dokumente werden in Text-Chunks (z. B. 512–1024 Tokens) zerlegt und mit einfachen Embeddings oder Schlagwort-Indizes versehen.
- Skills (Fristen-, Kosten-, Kündigungs-Check) wählen nur die relevanten Chunks für die jeweilige Fragestellung aus.
- Das LLM sieht nur die wichtigsten Chunks und bleibt damit fokussiert; Tokenverbrauch und Antwortzeit werden reduziert.

7. UX-Empfehlungen für DokuCheck Lokal

Damit DokuCheck als Produkt klar positioniert ist:[\[golem\]](#)

- Klare Workflows: „Dokument hochladen → Sprache/Profil wählen → Skill auswählen → Ergebnis als Report exportieren“.
 - Sichtbarer Datenschutz-Hinweis: Anzeige der Anzahl externer Requests (z. B. „Analyse-Requests nach außen: 0“) und Erklärung der lokalen Verarbeitung.
 - Vordefinierte Use-Case-Presets (z. B. Mietvertrag, Mobilfunkvertrag, Versicherung, Dienstleistungsvertrag).
 - Export-Funktionen für Ergebnisse (Markdown, HTML, JSON, DOCX), damit Nutzer Berichte speichern und weiterverwenden können.
-